

Prédiction du Churn Client

DATASET TELCO CUSTOMER CHURN — IBM SAMPLE

Du cadrage métier au modèle déployé : un projet complet de classification supervisée.

84,61 %

ROC-AUC du modèle final
(régression logistique calibrée)

0,15

Seuil de décision retenu
(optimisé sur le coût métier)

7 043

Clients analysés
(26,54 % de churn)

Table des matières

6

missions couvertes,
du cadrage au déploiement

3

modèles comparés en
validation croisée

5/5

tests automatisés
passants

Section	Contenu	Résultat clé
M0	Cadrage du problème — coûts d'erreur, métrique, seuil de réussite	Recall ≥ 80 % visé
M1	Données et analyse exploratoire — qualité, fuite de données, insights	26,54 % de churn
M2	Préparation et pipeline — split, ColumnTransformer, baseline	ROC-AUC 84,19 %
M3	Benchmark des modèles — 3 familles, test statistique, erreurs	Rég. logistique retenue
M4	Optimisation, calibration, SHAP et seuil de décision	Seuil optimal 0,15
M5	Déploiement — sérialisation, tests, API FastAPI	5/5 tests ✓

Fil conducteur du rapport : chaque mission s'appuie sur les décisions prises à l'étape précédente — le coût métier fixé en cadrage (M0) guide directement le choix du seuil de décision final (M4), et la rigueur du pipeline (M2) conditionne la fiabilité de tous les résultats qui suivent.

Cadrage du problème

Problème métier. Dans le secteur des télécommunications, le départ des clients, appelé *churn*, représente un enjeu important pour l'entreprise. L'objectif de ce projet est de développer un modèle de classification capable d'identifier les clients susceptibles de résilier leur abonnement afin que le service marketing ou de fidélisation puisse leur proposer en priorité une offre de rétention. La variable cible Churn indique si le client a résilié (Yes) ou non (No) — un problème de classification binaire.

Coûts des erreurs

Les deux types d'erreurs n'ont pas les mêmes conséquences : un faux négatif correspond à un client qui résilie mais que le modèle n'identifie pas comme à risque, tandis qu'un faux positif correspond à un client fidèle identifié à tort comme susceptible de partir.

300 €

coût d'un Faux Négatif
(client perdu, non détecté)

50 €

coût d'un Faux Positif
(offre envoyée à tort)

× 6

un FN coûte 6 fois plus cher
qu'un FP

Il est donc préférable de cibler quelques clients fidèles inutilement plutôt que de manquer des clients réellement susceptibles de partir. Ces montants sont des hypothèses métier définies pour le projet.

Métriques et seuil de réussite

La métrique principale retenue est le **Recall** de la classe Churn, car il mesure la capacité du modèle à identifier les clients qui vont réellement résilier — privilégiant la réduction des faux négatifs. La Precision et le F1-score serviront de métriques secondaires. L'accuracy ne sera pas privilégiée en raison du déséquilibre des classes (~27 % de churn).

Le seuil de 0,5 ne sera pas considéré comme optimal a priori : plusieurs seuils seront comparés pour retenir celui offrant le meilleur compromis au regard des coûts métier définis ci-dessus.

Risques et hypothèses

- La distribution des données peut évoluer (tarifs, offres, concurrence) → surveillance du *data drift* / *concept drift* nécessaire.
- Respect des règles de protection des données personnelles.
- Explicabilité importante pour les équipes métier.
- Pas de contrainte de temps réel strict, mais résultats suffisamment rapides pour agir avant le départ du client.

Recall

métrique principale retenue

≥ 80 %

objectif fixé a priori
sur la classe Churn

Données et analyse exploratoire

L'analyse exploratoire a été réalisée sur le jeu de données **Telco Customer Churn**, qui contient 7 043 clients et 21 variables décrivant leurs caractéristiques démographiques, leur ancienneté, les services souscrits, leur contrat, leur mode de paiement et leurs charges.

7 043

clients, 21 variables
aucun doublon détecté

11

valeurs non convertibles
dans TotalCharges (tenure = 0)

r = 0,83

corrélation tenure ↔
TotalCharges_num

Qualité, structure et fuite de données

Le dataset présente une qualité globale satisfaisante : les 7 043 identifiants `customerID` sont uniques et aucune variable quasi-constante n'a été identifiée (seuil 95 %). La vérification des valeurs manquantes avec `isna()` n'en détecte aucune ; une analyse spécifique de `TotalCharges` a toutefois révélé 11 valeurs non convertibles, toutes associées à des clients d'ancienneté nulle (`tenure = 0`). Une version numérique `TotalCharges_num` a été utilisée pour l'EDA, sans imputation définitive à ce stade.

Une vérification de fuite de données a été menée : aucune variable ne présente de relation quasi parfaite avec la cible, et aucune information n'est disponible uniquement après la résiliation. `customerID` sera exclu de la modélisation (identifiant sans valeur prédictive généralisable).

✓ **Aucune fuite de données détectée** — toutes les variables retenues sont disponibles pendant la relation client, avant toute décision de résiliation.

Analyse du churn

26,54 %

taux global de churn
(1 869 / 7 043 clients)

42,71 %

churn en contrat mensuel
(Month-to-month)

2,83 %

churn en contrat
de deux ans

L'ancienneté est également fortement associée au churn : les clients ayant résilié ont une ancienneté médiane de **10 mois**, contre **38 mois** chez les clients restés, et des charges mensuelles moyennes plus élevées (74,44 € contre 61,27 €). Le churn atteint également 45,29 % chez les utilisateurs du paiement *Electronic check*, 41,89 % chez les clients fibre optique, 41,64 % chez les clients sans support technique et 41,68 % chez les clients seniors.

Variables les plus discriminantes (information mutuelle)

Rang	Variable	Information mutuelle
1	Contract	0,0985
2	tenure	0,0673
3	OnlineSecurity	0,0647
4	TechSupport	0,0630
5	InternetService	0,0556

Trois insights majeurs

- 01 Le type de contrat est fortement associé au churn.** 42,71 % en contrat mensuel contre 2,83 % en contrat de deux ans — l'engagement est une caractéristique clé pour identifier les clients à risque.
- 02 Les nouveaux clients résilient davantage.** Ancienneté médiane de 10 mois (churn) contre 38 mois (fidèles) — les premières périodes de la relation client sont critiques pour la rétention.
- 03 Internet et support sont associés au churn.** Fibre optique : 41,89 % ; sans support technique : 41,64 % ; contre 15,17 % avec support technique.

Hypothèses retenues (vérifiées graphiquement) : (1) contrat mensuel → plus de churn ; (2) faible ancienneté → plus de churn ; (3) absence de support technique (parmi les clients Internet) → churn plus élevé ; (4) fibre optique → churn supérieur aux autres types d'accès Internet. Ces hypothèses guideront le feature engineering de la Mission 2.

Préparation et pipeline

Séparation des données et pipeline

5 634clients — ensemble
d'entraînement**1 409**clients — ensemble
de test**26,54 %**taux de churn identique
dans les deux ensembles

Le split est stratifié sur Churn. Le prétraitement est intégré dans un `ColumnTransformer` : les variables numériques (`tenure`, `MonthlyCharges`, `TotalCharges`) sont imputées par la médiane puis standardisées ; les variables catégorielles sont imputées par leur modalité la plus fréquente puis encodées en `OneHotEncoder`. Les statistiques de transformation sont apprises uniquement sur le train — le test n'intervient qu'à la prédiction.

Résultat de la baseline (régression logistique)

80,55 %

Accuracy

55,88 %

Recall

60,40 %

F1-score

84,19 %

ROC-AUC

Le ROC-AUC de 0,8419 montre une bonne capacité de discrimination, mais le Recall de 55,88 % signifie que seuls **209 des 374 clients** ayant réellement résilié sont détectés — **165 clients manqués**, un problème important vu le coût élevé des faux négatifs (300 € chacun).

Évaluation du feature engineering

Trois variables ont été testées séparément : `tenure_group`, `NumServices` et `ChargesPerTenure`.

Modèle	Accuracy	Recall	F1-score	ROC-AUC
Baseline	0,8026	0,5431	0,5930	0,8461
<code>tenure_group</code>	0,8058	0,5358	0,5936	0,8464
<code>NumServices</code>	0,8019	0,5431	0,5921	0,8462
<code>ChargesPerTenure</code>	0,8021	0,5452	0,5932	0,8457

Décision : pipeline baseline conservé. Aucune feature n'apporte de gain suffisant et stable (conforme au rasoir d'Occam) — un modèle plus simple reste préférable, y compris pour l'interprétabilité.

Questions de réflexion

3.1 — Concept Drift

Un modèle performant à l'entraînement peut se dégrader en production si le comportement des clients évolue (nouvelles offres, changements tarifaires, habitudes). Il faut surveiller régulièrement les performances (Accuracy, Precision, Recall, F1, ROC-AUC) ainsi que la distribution des données (Data Drift), et réentraîner en cas de baisse importante.

3.2 — Information mutuelle

Contrairement à la corrélation de Pearson, qui ne détecte que les relations linéaires, l'information mutuelle mesure aussi les dépendances non linéaires. Elle a permis d'identifier Contract, tenure, OnlineSecurity, TechSupport et InternetService comme variables les plus informatives.

3.3 — Théorème « No Free Lunch »

Aucun algorithme n'est universellement meilleur pour tous les problèmes : les performances dépendent des caractéristiques du jeu de données. Cela justifie le benchmark réalisé (Mission 3), qui a permis de retenir la régression logistique — meilleur compromis performance / interprétabilité / simplicité de déploiement.

3.4 — Fairness

Vérifier que le modèle produit des prédictions équitables entre sous-groupes (genre, âge, type de contrat), via la *Demographic Parity* (proportion de prédictions positives) ou l'*Equalized Odds* (taux de vrais/faux positifs comparés). Non réalisée dans ce projet — amélioration importante avant mise en production.

3.5 — Fuite de données (Data Leakage)

Risque d'utiliser des informations du test pendant l'entraînement. Évité ici par : séparation des données avant toute transformation, Pipeline scikit-learn ajusté uniquement sur le train, et jeu de test réservé à l'évaluation finale — garantissant une évaluation fiable et reproductible.

Benchmark des modèles

Baseline naïve

73,46 %

accuracy en prédisant
toujours « No »

0 %

Recall et F1-score
pour la classe « Yes »

L'accuracy seule peut être trompeuse sur ce problème déséquilibré — d'où l'usage du Recall, F1-score et ROC-AUC comme métriques de référence.

Comparaison des modèles (validation croisée, 5 plis stratifiés)

Modèle	Accuracy ± σ	Recall ± σ	F1-score ± σ	ROC-AUC ± σ
Régression logistique ★	0,8026 ± 0,0120	0,5431 ± 0,0411	0,5930 ± 0,0298	0,8461 ± 0,0125
XGBoost	0,8017 ± 0,0130	0,5298 ± 0,0285	0,5864 ± 0,0268	0,8435 ± 0,0096
Random Forest	0,7854 ± 0,0110	0,4816 ± 0,0272	0,5434 ± 0,0235	0,8204 ± 0,0121

La régression logistique obtient les meilleurs résultats sur les métriques clés (Recall, F1-score, ROC-AUC). XGBoost est proche, Random Forest moins performant. La régression logistique est retenue — simple, interprétable, adaptée au déploiement.

Test statistique (Wilcoxon)

4,0

statistique de test

0,4375

p-valeur (> 0,05)

Différence non significative entre régression logistique et XGBoost. La régression logistique est conservée pour ses meilleures performances moyennes et sa simplicité.

Analyse des erreurs

109

faux positifs, tous en
contrat Month-to-month

Ancienneté moyenne de 12,83 mois (médiane 8 mois), majoritairement fibre optique + *Electronic check* — des profils intermédiaires à risque qui restent finalement fidèles.

Optimisation et modèle final

Optimisation avec Optuna (50 essais, MedianPruner, 8 hyperparamètres)

0,5930

F1-score — paramètres
par défaut

0,6310

F1-score — après
optimisation

+6,4 %

gain relatif
(+0,0380 absolu)

Hyperparamètre	Valeur optimale
Solver	saga
Penalty	elasticnet
C	0,1813
Class weight	balanced importance 0,75
Fit intercept	False
Tol	0,000502
Max iter	1 284 importance 0,24
L1 ratio	0,9122

`class_weight` est le paramètre le plus influent (importance $\approx 0,75$) : le poids équilibré compense le déséquilibre des classes et améliore la détection des clients churneurs.

Calibration des probabilités

Le modèle optimisé surestimait initialement les probabilités de churn (courbe sous la diagonale de calibration). Une calibration `CalibratedClassifierCV` (Platt / sigmoid) rapproche la courbe de la diagonale idéale.

Une probabilité mieux calibrée permet au service de fidélisation de **hiérarchiser** les clients selon leur niveau de risque réel — essentiel puisque l'API expose une probabilité, pas seulement une classe.

Interprétabilité SHAP

Variables les plus influentes : **tenure** (faible ancienneté → risque plus élevé), **MonthlyCharges** (charges élevées → risque accru), et **Contract** (Month-to-month augmente le risque, Two year le réduit) — cohérent avec les insights de l'EDA.

Choix du seuil de décision

0,617

F1-score maximal
(seuils 0,30–0,35)

0,15

seuil optimal
(coût métier minimal)

31 650 €

coût total minimal
(32 FN, 441 FP)

Seuil retenu : 0,15. À 0,50, le F1-score n'est que de 0,598 et davantage de clients à risque passent inaperçus. Le seuil de 0,15 privilégie la détection des clients à risque, conformément à l'objectif métier fixé en Mission 0 (coût du FN = 6× celui du FP).

Déploiement et validation

Sérialisation et tests automatisés



prédiction identique
après rechargement joblib

5 / 5

tests pytest
passants

0,7429

probabilité de churn —
client de vérification

Le pipeline final (optimisé et calibré) est sauvegardé avec joblib dans `model/modele_final_calibre.joblib`. Cinq tests pytest couvrent : la forme de la sortie, la validité des probabilités, la gestion des valeurs manquantes, la présence des variables attendues, et le maintien des performances sur un mini-jeu de référence.

API FastAPI — trois endpoints

Endpoint	Méthode	Rôle	Résultat observé (curl)
/health	GET	Vérification de l'état de l'API et de sa version	status = OK
/model-info	GET	Variables attendues, métadonnées, métriques	Accuracy 0,8026 · Recall 0,5431 · F1 0,593 · ROC-AUC 0,8461
/predict	POST	Prédiction du churn et probabilité associée	Yes — proba 0,715

Les trois endpoints ont été testés avec curl et répondent conformément aux attentes — le système est prêt pour une intégration côté service marketing.

Conclusion

Ce projet a suivi l'intégralité du cycle de vie d'un projet de Machine Learning supervisé, du cadrage métier (Mission 0) à une API fonctionnelle en production (Mission 5), en respectant strictement la contrainte de non-fuite de données à chaque étape.

84,61 %

ROC-AUC du modèle final
(rég. logistique calibrée)

0,15

seuil de décision retenu
(orienté coût métier)

31 650 €

coût total minimal estimé
sur le jeu de test

5 / 5

tests automatisés
passants avant mise en
prod

Ce que ce projet démontre

- Un modèle simple et bien interprété (régression logistique + SHAP) peut être préférable à un modèle plus complexe, à condition d'un benchmark rigoureux (Mission 3) plutôt qu'un choix présupposé — illustration concrète du théorème *No Free Lunch*.
- Le coût métier défini dès le cadrage (FN = 6× FP) doit guider directement le choix du seuil de décision final, pas uniquement les métriques statistiques comme le F1-score.
- Un pipeline scikit-learn rigoureux (split avant transformation, fit exclusivement sur le train) garantit une évaluation fiable, reproductible et sans fuite de données.

Prochaines étapes suggérées : compléter l'audit de fairness entre sous-groupes (non traité dans ce projet), mettre en place un monitoring de data/concept drift en production, et réévaluer périodiquement le modèle sur des données plus récentes.